QRL-Lab: είσοδος, αποτελέσματα και αρχιτεκτονικές των μοντέλων

cycle 3 · batch S · workload `poisson_ms_spiky` (και shift)

Πάρις — ετοιμάστηκε για τον Κώστα (M-20261110-003, J444)

10/11/2026

1 Τι περιέχει και τι ΟΧΙ

- Όλα τα νούμερα είναι **validation** (spiky: val 16000–16019, shift: val 13500–13509) · **κανένα test split** δεν χρησιμοποιήθηκε, καμία νέα εκπαίδευση. Δεν είναι συμπέρασμα γενίκευσης ούτε claim.
- Τα σχήματα adaptation (pods vs load) προέρχονται από **eval-only** επανεκτέλεση των αποθηκευμένων checkpoints του training seed 19100 (ένα seed ανά μοντέλο) σε 3 val επεισόδια (seeds 16000–16002), μέσω `tools/envelope.py` (envelope cycle3). Άρα δείχνουν συμπεριφορά ενός εκπαιδευμένου μοντέλου, όχι μέσο όρο seeds.
- Το RPPO/DRe-SCale έχει δικό του module (`tuning/rppo.py`) χωρίς καταγραφή τροχιάς · ΔΕΝ υπάρχει σχήμα pods-vs-load γι' αυτό (τα νούμερα return και η αρχιτεκτονική υπάρχουν). Δεν επινοήθηκε τίποτα.
- Το latency είναι *proxy* (χρόνος παραμονής στην ουρά + l_0 τη στιγμή της αποδοχής), όχι μετρημένος χρόνος απόκρισης (`tuning/poisson_ms.py`, docstring).
- Οι αρχιτεκτονικές διαβάστηκαν από τον κώδικα και από τα `.pt` checkpoints · ο αριθμός παραμέτρων μετράται από τα state_dict (συμφωνεί με `n_params` των JSON).

2 Είσοδος: workload και μετρικές

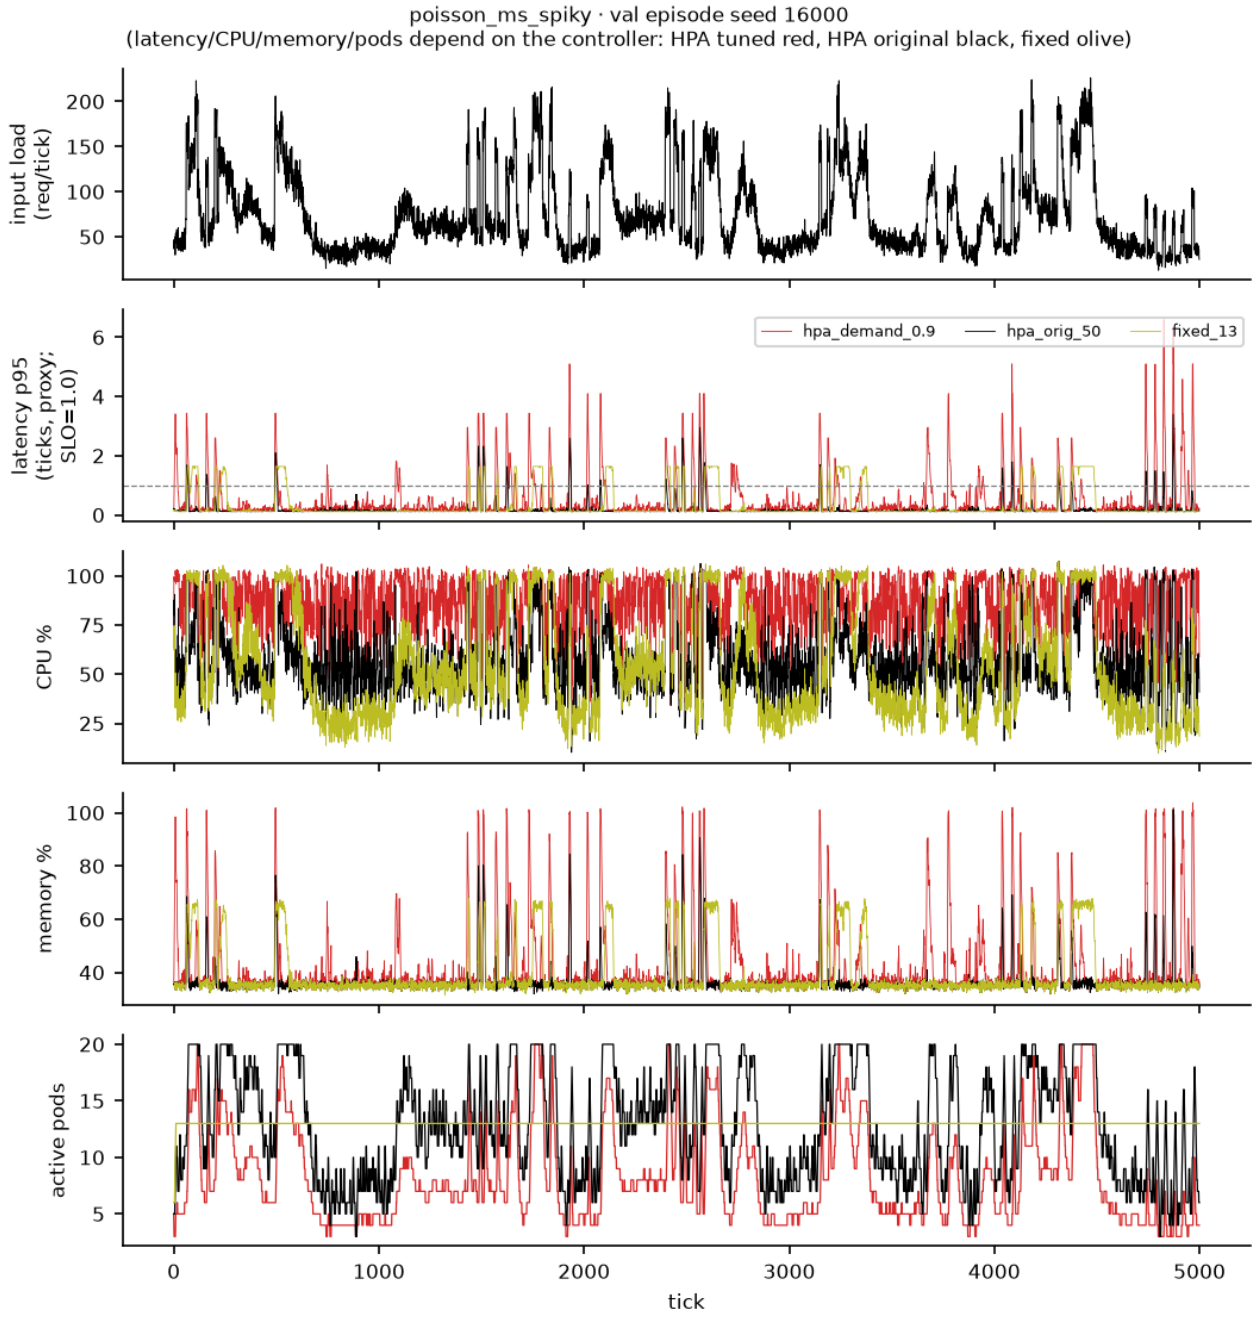
Περιβάλλον: ουρά αιτημάτων με πόδια (pods) 1–20, $\mu = 10$ αιτήματα/pod/tick, καθυστέρηση εκκίνησης pod 5 ticks, ουρά max 200, SLO: p95 latency > 1.0 ή drops, κόστος pod 3/tick, ποινή SLO 20, ποινή drop 1 ανά αίτημα, επεισόδιο 5000 ticks, αρχικά 6 pods. Ρυθμός: $\lambda_t = \text{base} \cdot (1 + 0.4\sin(2\pi t/1000 + \varphi)) \cdot e^{x_t}$ (AR(1) log-noise, $\phi = 0.98$, $\sigma = 0.15$), $N_t \sim \text{Poisson}(\lambda_t)$. Η `spiky` παραλλαγή αντικαθιστά τη μαρκοβιανή έκρηξη με επικάλυψη γεγονότων (απότομα flash-crowds, ράμπες, ριπές), με $\lambda \leq 190$. Η `shift` έχει συχνότερες εκρήξεις ($r_{nb} = 1/300$) και $\sigma = 0.30$. Δράσεις: 0 κάτω / 1 μένω / 2 πάνω. Reward $= \text{served} - 3 \cdot \text{pods} - 20 \cdot [\text{SLO}] - \text{drops}$. `code-poisson-c345/tuning/poisson_ms.py:1-34,55-124`.

State 7 διαστάσεων: [arrivals, capacity, CPU%, mem%, p95 latency, active pods, pending pods] · κανονικοποίηση (obs_scale) με διαιρέτες 100,100,100,100,2,20,20 και reward/10 (`S/c3S-dinos-s19100.json`).

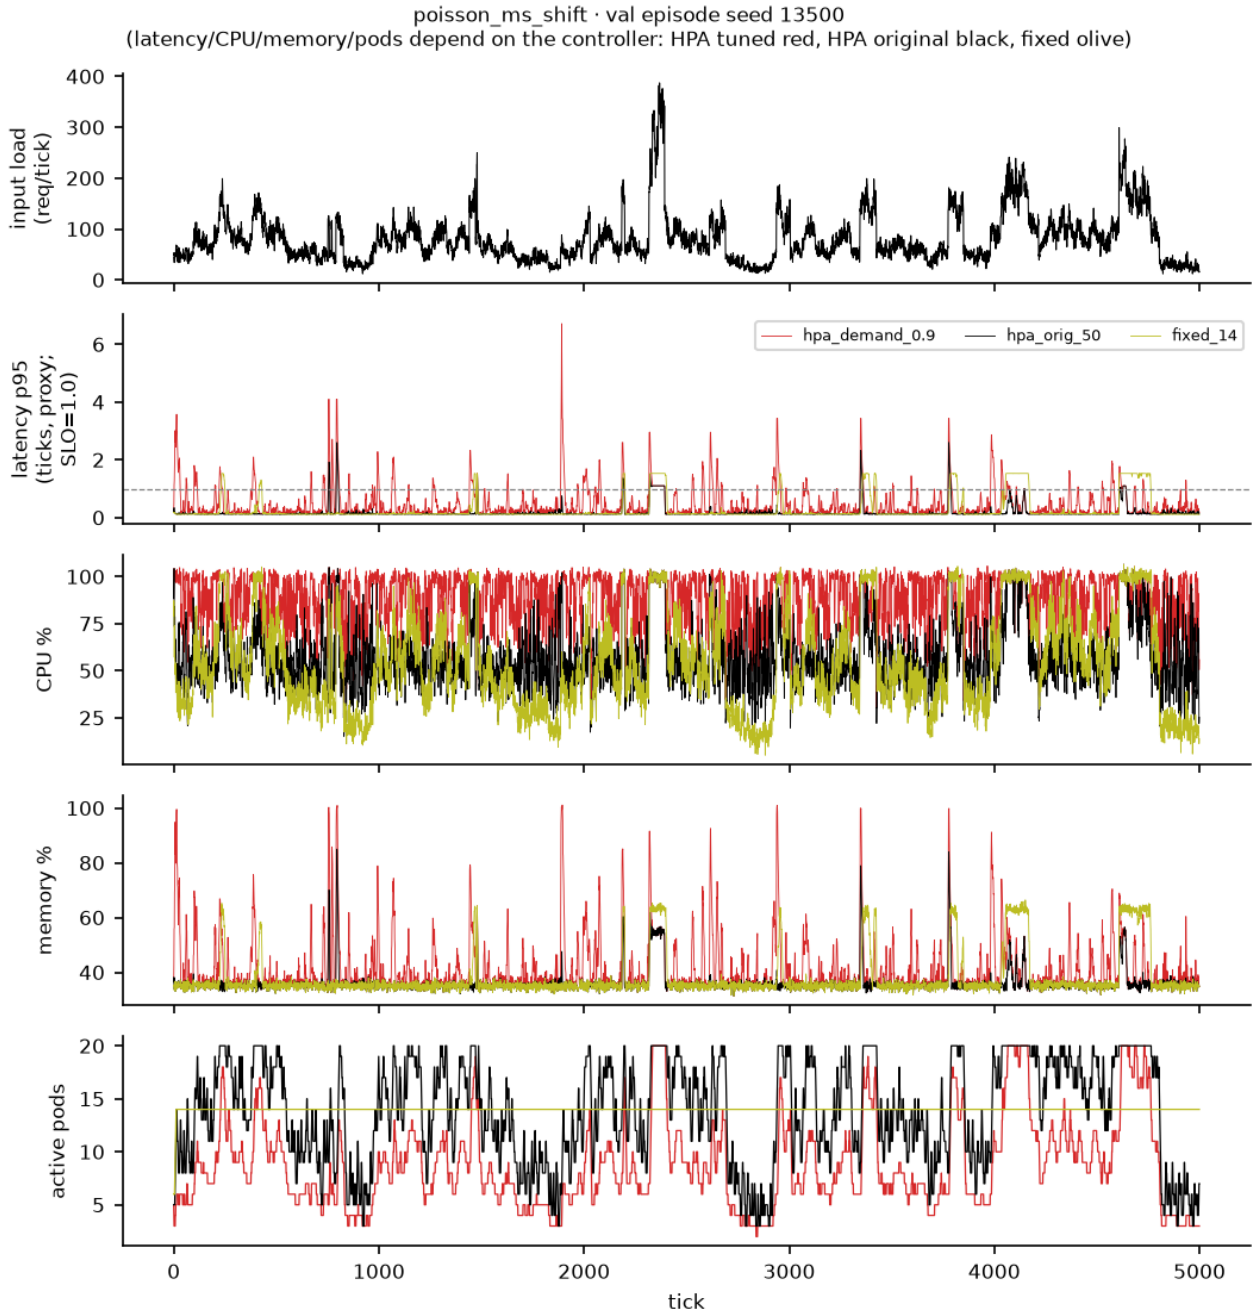
3 Συνολικό reward ανά μοντέλο

Μοντέλο	μέσο	SD	διάμεσος	min seed	max seed	SLO viol.	παράμετροι
Dinos	191.600	7.100	194.839	179.310	198.179	0.106	104.451
Dinos+Transfer V.2	188.131	12.028	193.814	157.622	196.609	0.103	104.451
LSTM+transfer	179.877	7.668	182.139	161.564	186.441	0.145	334.723
LSTM	164.648	10.901	160.015	152.236	181.322	0.224	334.723
DERP (original)	153.579	29.403	159.519	109.306	186.855	0.048	17.923
DERP enhanced (hist10)	91.481	149.827	172.010	-196.017	197.699	0.355	25.987
RPPO / DRe-SCale	86.009	113.946	158.219	-155.721	178.669	0.386	584.196
HPA original (thr 50)	152.439	20.709	20 val episodes			–	–
Tuned HPA (0.9)	201.856	15.482	20 val episodes			–	–
Oracle look-ahead (1.1)	222.674	17.020	20 val episodes			–	–
Fixed 13 pods	119.208	16.259	20 val episodes			–	–

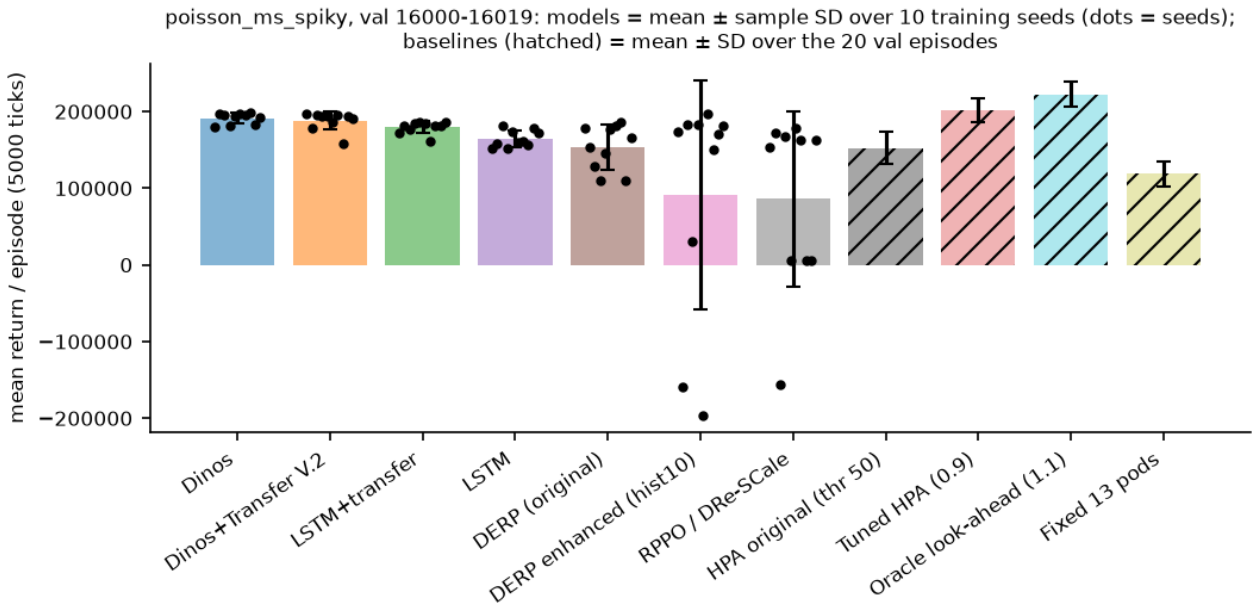
Table 1: Πηγή: `.lab/j442/summary.json` (μοντέλα), `code-poisson-spiky/tuning/results/spiky-stage1/spiky1-P0-reference-off-s16000.` (baselines). Ο oracle είναι look-ahead ευρετικός, όχι άνω φράγμα (`docs/paper_notes.md` §6).



Είσοδος (spiky, val seed 16000): load και, για τρεις ελεγκτές αναφοράς, latency p95, CPU, μνήμη και pods. Τα CPU/mem/latency εξαρτώνται από τον ελεγκτή · δεν είναι ιδιότητα της εισόδου μόνο. Πηγή: eval-only `base_spiky.json`.

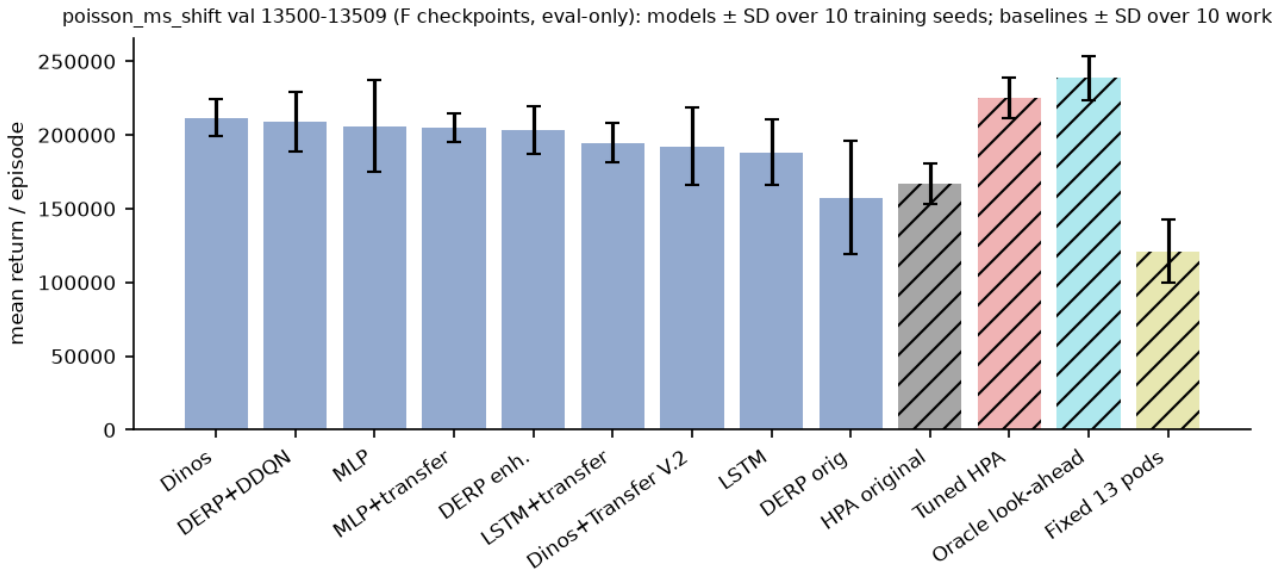


Ίδιο για το shift workload (val seed 13500).



Return ανά επεισόδιο, spiky val. Μοντέλα: μέσο ± sample SD των 10 training seeds 19100–19109 (μία κουκκίδα ανά seed, μέσος 20 val επεισοδίων, ένα checkpoint 19968 ticks). Baselines: μέσο ± SD των 20 val επεισοδίων με παραμέτρους επιλεγμένες στο ίδιο val (P0) · δεν είναι ανεξάρτητα από το val.

Παρατηρήσεις (περιγραφικά): όλα τα μοντέλα είναι κάτω από το tuned HPA (201,9k) και τον oracle (222,7k) · Dinos και Dinos+Transfer V.2 δεν διακρίνονται (paired διαφορά $-3{,}5\text{k} \pm 16{,}9\text{k}$, `.lab/j442`). DERP enhanced και RPPO είναι ασταθή (seeds με αρνητικό return).

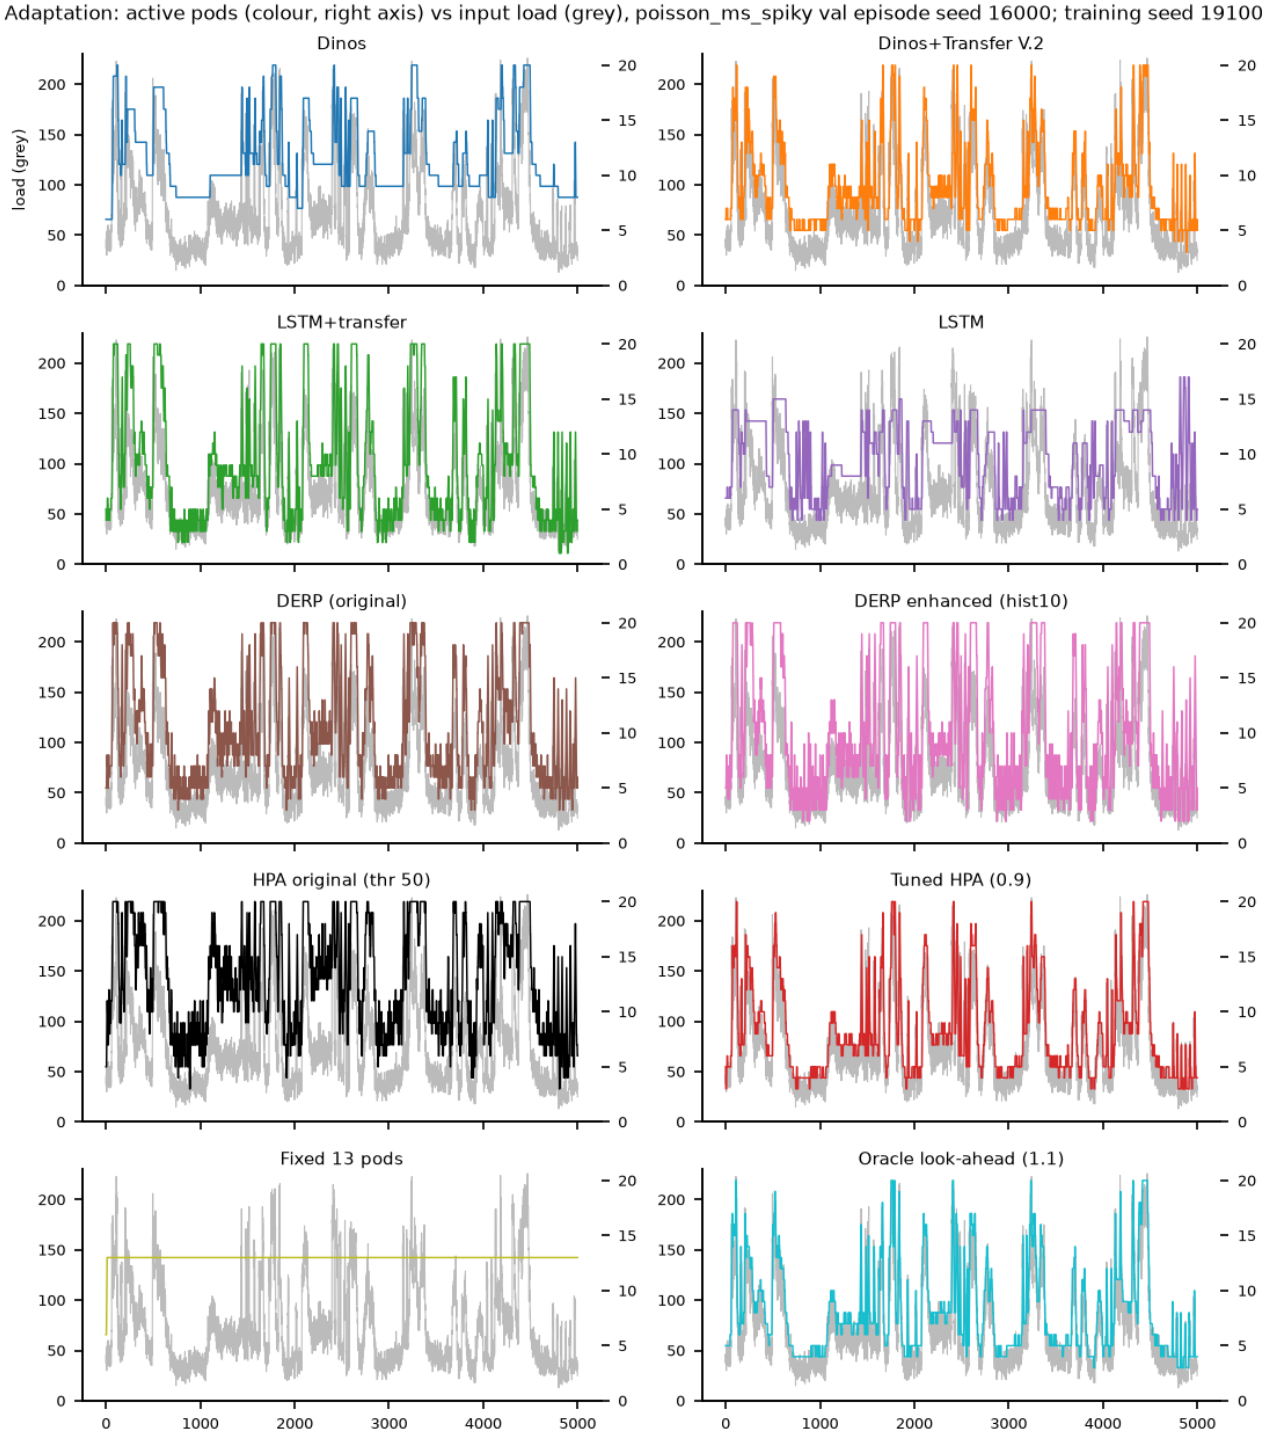


Shift workload (held-out), τα checkpoints F (10 seeds, 39936 ticks) αξιολογημένα eval-only στο val. Πηγή: `.lab/j438/summary.json`. Περιγραφικό, όχι test.

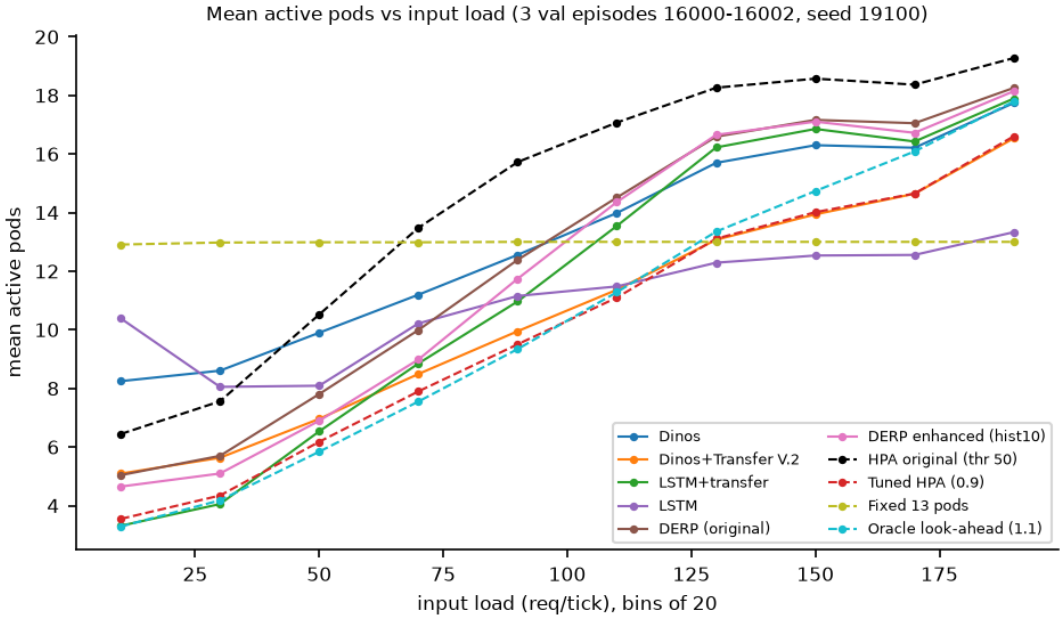
4 Προσαρμογή: pods ως προς το load

5 Αρχιτεκτονικές των μοντέλων

Κοινά (αν δεν αναφέρεται διαφορετικά): 3 δράσεις, reward/10, κανονικοποιημένη είσοδος 7 χαρακτηριστικών, Adam, απώλεια SmoothL1 (Huber), Double DQN (online argmax / target τιμή, detached) για τους LSTM arms, replay από μνήμη, 16 διαδοχικές ενημερώσεις ανά replay, ένα



Pods (έγχρωμο, δεξιός άξονας) και load (γκρι) στο ίδιο val επεισόδιο, ένα training seed (19100) ανά μοντέλο · στο τέλος οι ελεγκτές αναφοράς.



Μέσος αριθμός pods ανά κλάση load. Ένα training seed, 3 val επεισόδια.

replay ανά tick όταν η μνήμη $>$ 16. Παράθυρο ιστορικού 10 ticks για τα LSTM. Training 19968 ticks target (transfer: 9984 pretrain + 9984 finetune, συνολικά 19968). Πηγές: `tuning/legacy/{network_dense,networks_lstm,agent_lstm_fixed,agent_lstm_v2,ddqnagent,c5_protocol}.py`, `tuning/rppo.py`, και τα JSON του batch S `tuning/results/cycle3/S/`.

Μοντέλο	Δίκτυο	params	lr	batch	γ	replay	n-step	target sync
DERP original	MLP 7-128-128-3	17.923	10^{-4}	16	0.95	500	–	κάθε replay
DERP enhanced	MLP 70-128-128-3	25.987	10^{-4}	16	0.95	500	–	κάθε replay
LSTM	3×LSTM(128)+FC	334.723	10^{-4}	16	0.98	5000	2	100
LSTM+transfer	3×LSTM(128)+FC	334.723	10^{-4}	16	0.98	5000	1	250
Dinos	LSTM128 → concat → 128 → 128	104.451	$5 \cdot 10^{-5}$	16	0.98	5000	3	100
Dinos+Transfer V.2	ίδιο με Dinos	104.451	10^{-4}	16	0.98	5000	5	250
RPPO / DReSCale	LSTM256 + MLP 64-64 (actor, critic)	584.196	$3 \cdot 10^{-4}$	128	0.99	rollout 128	–	–

Table 2: Σύνοψη. Πηγές: JSON του S (`hyperparameters`, `ddqn_options`, `target_sync_replays`, `learning_rate`), `ddqnagent.py:15-30`, `agent_lstm_fixed.py:1-16,153-154`, `rppo.py:1-13,44-45`. Το batch size των DQN arms είναι τα 16 δείγματα ανά replay (`run_legacy.py:127`); το «batch» του RPPO είναι ολόκληρο το rollout των 128 βημάτων.

5.1 DERP (original) — `derp`

Πυκνό δίκτυο: `fc1` Linear(7,128) → ReLU → `fc2` Linear(128,128) → ReLU → `fc3` Linear(128,3) (Q-τιμές των 3 δράσεων). Πλήρως συνδεδεμένα (fully connected), χωρίς μνήμη: βλέπει μόνο την τρέχουσα παρατήρηση. 17.923 παράμετροι. Αλγόριθμος: DDQN του αρχικού DInos (verbatim port), μνήμη 500, $\gamma = 0.95$, Adam 10^{-4}, SmoothL1, replay(16) κάθε tick. ϵ: γραμμικά 1→0.01 σε 10k ticks (`linear10k`, `epsilon_min`=0.01 στο JSON). Στόχος: $r + \gamma \max_a Q_{\text{target}}(s', a)$ όπως στο αρχικό · στο S δεν ενεργοποιείται double/n-step. Χωρίς transfer.

5.2 DERP enhanced — `derp_hist10`

Ίδιο δίκτυο, αλλά είσοδος η ισοπεδωμένη ιστορία 10 παρατηρήσεων (10×7=70): Linear(70,128)→ReLU→Linear(128,128)→ReLU→Linear(128,3), 25.987 παράμετροι. ϵ: πολλαπλασιαστικά ×0.995 ανά replay (`eps_schedule=original`), ελάχιστο 0.01. Άλλα ίδια με το DERP. Ασταθές στο S (SD 149,8k).

5.3 LSTM — `lstm_scratch`, variant `fixed`

Αναδρομικό δίκτυο (LSTM) `myLSTM`: είσοδος παράθυρο [10×7] → 3 στοιβαγμένα επίπεδα LSTM με 128 κρυφούς νευρώνες το καθένα (τα h, c ξεκινούν από μηδέν σε κάθε παράθυρο) → η έξοδος του τελευταίου tick → Linear(128,3). Σύνδεση: μέσα στο κάθε επίπεδο οι νευρώνες συνδέονται με πύλες (input, forget, cell, output) και αναδρομικές συνδέσεις · τα επίπεδα συνδέονται σειριακά. 334.723 παράμετροι. Double DQN με n-step 2, $\gamma = 0.98$, μνήμη 5000, 16 ενημερώσεις ανά replay, target sync κάθε 100 replays, lr 10^{-4}, ϵ 1→0.05 γραμμικά σε 10k ticks.

5.4 LSTM+transfer — `dinos_t`, variant `fixed`

Ίδιο δίκτυο με το LSTM. Pretraining 9984 ticks στο `spike300_d5` (cycle-1 περιβάλλον, ίδιο μέγεθος state), μετά finetune 9984 ticks στο `poisson_ms_spiky` με επανεκκίνηση ϵ (restart). n-step 1, target sync 250, lr 10^{-4}. Ο αριθμός παραμέτρων είναι ίδιος (334.723).

5.5 Dinos — `lstm_scratch`, variant `a1h`

«Dinos V.2-H»: `window[10×7]` → `LSTM(7,128, 1 επίπεδο, μηδενικά` h, c `ανά παράθυρο)` → `concat(τελευταία έξοδος[128], τελευταία παρατήρηση[7])` → `Dense(135,128) ReLU` → `Dense(128,128) ReLU` → `Dense(128,3)` (πεδίο `architecture` του JSON). Δηλαδή ένα LSTM που συνοψίζει την ιστορία, ενώνεται (skip σύνδεση) με την τρέχουσα παρατήρηση και περνά από 3 πυκνά επίπεδα. 104.451 παράμετροι. Double DQN, n-step 3, $\gamma = 0.98$, μνήμη 5000, 16 ενημερώσεις/replay, target sync 100 replays, Adam lr $5 \cdot 10^{-5}$, gradient clipping max-norm 10, ϵ 1→0.05 σε 10k ticks. Χωρίς pretraining. Σημείωση: το grad-clip ενεργοποιείται σχεδόν πάντα (clip_frac 0,988 στο seed 19100, `c3S-dinos-s19100.json`, `grad_norm`).

5.6 Dinos+Transfer V.2 — `dinos_t`, variant `a1h`

Ίδια αρχιτεκτονική με το Dinos (104.451 παράμετροι) · η διαφορά είναι στην εκπαίδευση: pretraining 9984 ticks στο ίδιο workload `poisson_ms_spiky`, μετά finetune 9984 ticks με restart του ϵ (συνολικά 19968) · n-step 5, target sync 250, lr 10^{-4}, χωρίς grad-clip στο JSON (`hyperparameters`). Ονομασία πάντα «Dinos+Transfer V.2».

5.7 RPPO / DRe-SCale — `rppo`

Recurrent PPO (native torch υλοποίηση, `tuning/rppo.py`, όπως οι προεπιλογές sb3_contrib): δύο ξεχωριστά LSTM 256 νευρώνων (ένα για τον actor, ένα για τον critic, `lstm_pi`, `lstm_vf`, είσοδος 7), μετά MLP [64,64] με Tanh ανά κλάδο, κεφαλή πολιτικής Linear(64,3) (κατηγορική κατανομή) και κεφαλή τιμής Linear(64,1). 584.196 παράμετροι. Hyperparameters (JSON): n_steps 128, batch 128 (ένα minibatch ανά rollout), n_epochs 10, lr $3 \cdot 10^{-4}$ (Adam, eps 10^{-5}), $\gamma = 0.99$, GAE $\lambda = 0.9$, clip 0.2, ent_coef 0, vf_coef 0.5, max_grad_norm 0.5, ορθογώνια αρχικοποίηση. On-policy · αξιολόγηση με greedy (argmax) πολιτική. Ασταθές στο S.

6 Αναπαραγωγή και όρια

Αριθμοί: `.lab/j442/summary.json`, `.lab/j438/summary.json` · σχήματα: `tools/j444/figs.py`, `tools/j444/build_pdf.py` · eval-only runs: spec `.lab/j444/spec.json` (envelope cycle3, χωρίς training, μόνο val). Ένα training seed ανά μοντέλο στα σχήματα προσαρμογής · τα 20 val επεισόδια του return δεν έχουν καταγραφεί ανά tick. Άγνωστο/μη διαθέσιμο: τροχιά RPPO · CPU-seconds του launcher για τα εξωτερικά runs (`cpu_seconds: None`).